Examen 1 Bioinfo

Fernanda Ximena Venegas García

2026-10-10

Introducción.

El objetivo del proyecto/examen es poder descargar las secuencias de un Bioproject obtenidas directamente de la página de NCBI, con la intención de analizarlas por medio de comandos de Bash y usando Jobs para esta labor.

El BioProject que usaremos es el siguiente: **PRJNA268110**. que corresponde a secuencias de Saccharomyces cerevisiae.

Contexto biológico.

Organismo estudiado: Saccharomyces cerevisiae (levadura de cerveza)

Cepa (Strain): WFA73

Objetivo del estudio: Determinar si las horquillas de replicación con huecos de DNA monocatenario tienen la misma probabilidad de producir rupturas de doble cadena.

Responsables del estudio: Wenyi Feng, Biochemistry and Molecular Biology, SUNY Upstate Medical University

Fecha aproximada de publicación de datos: 20-Nov-2014

Objetivo del estudio.

El objetivo del estudio o pregunta a responder es si las horquillas de replicación que tienen huecos de DNA monocatenario tienen la misma probabilidad de producir rupturas de doble cadena cuando intentan rehacerse de exposición a la Hidroxiurea.

Datos y metodología.

- Genoma de referencia (`GCF_000146045.2`)
- Organismo modelo: Saccharomyces Cerevisiae
- Datos de NCBI públicos

Fuentes de datos.

Bioproject: PRJNA268110

| BioSample | SRA Study |

|———————————|

| SAMN03203061 | SRP050091 |

| SAMN03203063 | SRP050091 |

| SAMN03203066 | SRP050091 |

| SAMN03203053 | SRP050091 |

| SAMN03203062 | SRP050091 |

| SAMN03203059 | SRP050091 |

| SAMN03203067 | SRP050091 |

| SAMN03203068 | SRP050091 |

| SRA Run | Experiment | Tipo de Secuenciacion | Paired/Single |

|———————————————————————————————-|

| SRR1658454 | SRX764815 | Illumina MiSeq | Paired |

| SRR1658455 | SRX764816 | Illumina MiSeq | Paired |

| SRR1658456 | SRX764817 | Illumina MiSeq | Paired |

| SRR1658457 | SRX764818 | Illumina MiSeq | Paired |

| SRR1658458 | SRX764819 | Illumina MiSeq | Paired |

| SRR1658459 | SRX764820 | Illumina MiSeq | Paired |

| SRR1658460 | SRX764821 | Illumina MiSeq | Paired |

| SRR1658461 | SRX764822 | Illumina Miseq | Paired |

Plataforma de secuenciamiento: Illumina

Tecnología usada: Illumina MiSeq

Formato de archivos: fastq, fastqc.html, fastqc.zip,

Información del genoma ensamblado:

Nombre del ensamblado: Saccharomyces Cerevisiae S288C, R64

Organismo: Saccharomyces Cerevisiae (Levadura)

Numero de Accession: GCF_000146045.2

Numero de cromosomas: 17

Tamaño del genoma: 12.1 mb

BioProject/BioSample/SRA.

- Bioproject: Agrupa todo el estudio, los datos usados en la investigación, los resultados (si ya hay), publicaciones, etc.
- BioSample: Es la muestra que se extrajo para estudiar
- SRA Experiment: Muestra como se preparó el dataset y el diseño experimental que se llevó a cabo.
- SRA Run: Contiene los datos crudos

Datos descargados.

Número de archivos descargados: 56 (ls -1 | wc -l)

Tamaño de cada archivo (Mb o Gb): Hay muchos archivos que son de K

(du -h *)

261M SRR1658454

741M SRR1658454_1.fastq

876K SRR1658454_1_fastqc.html

496K SRR1658454_1_fastqc.zip

740M SRR1658454_2.fastq

940K SRR1658454_2_fastqc.html

612K SRR1658454_2_fastqc.zip

449M SRR1658455_1.fastq

888K SRR1658455_1_fastqc.html

512K SRR1658455_1_fastqc.zip

449M SRR1658455_2.fastq

944K SRR1658455_2_fastqc.html

620K SRR1658455_2_fastqc.zip

185M SRR1658456

522M SRR1658456_1.fastq

900K SRR1658456_1_fastqc.html

540K SRR1658456_1_fastqc.zip

522M SRR1658456_2.fastq

884K SRR1658456_2_fastqc.html

520K SRR1658456_2_fastqc.zip

342M SRR1658457

960M SRR1658457_1.fastq

876K SRR1658457_1_fastqc.html

500K SRR1658457_1_fastqc.zip

960M SRR1658457_2.fastq

980K SRR1658457_2_fastqc.html

684K SRR1658457_2_fastqc.zip

461M SRR1658458

1.3G SRR1658458_1.fastq

880K SRR1658458_1_fastqc.html

500K SRR1658458_1_fastqc.zip

1.3G SRR1658458_2.fastq

960K SRR1658458_2_fastqc.html

640K SRR1658458_2_fastqc.zip

308M SRR1658459

870M SRR1658459_1.fastq

872K SRR1658459_1_fastqc.html

488K SRR1658459_1_fastqc.zip

870M SRR1658459_2.fastq

928K SRR1658459_2_fastqc.html

584K SRR1658459_2_fastqc.zip

255M SRR1658460

715M SRR1658460_1.fastq

880K SRR1658460_1_fastqc.html

504K SRR1658460_1_fastqc.zip

714M SRR1658460_2.fastq

952K SRR1658460_2_fastqc.html

632K SRR1658460_2_fastqc.zip

380M SRR1658461

1.1G SRR1658461_1.fastq

868K SRR1658461_1_fastqc.html

480K SRR1658461_1_fastqc.zip

1.1G SRR1658461_2.fastq

912K SRR1658461_2_fastqc.html

572K SRR1658461_2_fastqc.zip

Número de secuencias:

(grep -c "@SRR" *.fastq)

SRR1658454_1.fastq:3438388

SRR1658454_2.fastq:3438388

SRR1658455_1.fastq:2090805

SRR1658455_2.fastq:2090805

SRR1658456_1.fastq:2428934

SRR1658456_2.fastq:2428934

SRR1658457_1.fastq:4452257

SRR1658457_2.fastq:4452257

SRR1658458_1.fastq:6080904

SRR1658458_2.fastq:6080904

SRR1658459_1.fastq:4037197

SRR1658459_2.fastq:4037197

SRR1658460_1.fastq:3317701

SRR1658460_2.fastq:3317701

SRR1658461_1.fastq:4961938

SRR1658461_2.fastq:4961938

Reads: **6,080,90**

Longitud promedio de las lecturas:

75 pb (head -n 20 SRR1658458_1.fastq), todas son paired-end

Lineas y lecturas crudas.

Ejemplo (head -n 20 SRR1658458_1.fastq):

@SRR1658458.1 1 length=75 <- Identificador

CTTTCTCTTTCAGCCTTTAACTTGTCCAAAACCCAACCGTACTTTCACCCTCCCTTACCTTCTTCATCTTCTTCC <- Secuencia

+SRR1658458.1 1 length=75 <- Separador dentro de la secuencia.

8ABC@@<FEFD9,66EEE9AFFE6EFCCF<,;@6„,8+8„:@„„„„:66C@8CCF„;;C„;„6;;66 <- Contiene los valores de calidad de secuenciación

Herramientas utilizadas.

- NCBI BioProject
- NCBI BioSample
- NCBI Run Selector
- Servidor Ken
- Terminal de linux/bash

Resumen.

Se analizaron secuencias de Saccharomyces Cerevisiae por medio d ebases de datos públicas (NCBI), en las cuales encontramos los datos más importantes con respecto a las secuencias y a la calidad de las mismas para este BioProject que fue usado para llevar a cabo el examen/proyecto.

Entre algunas cosas que se ven al usar los comandos de Bash es la longitud promedio d elas lecturas (75), el peso de cada archivo, el cual es importante conocer antes de empezar a manipular todo, pues podría haber archivos demasiado pesados o que tu computadora no logre visualizar bien o lo hará, de momento, debemos buscar optimizar y ahorrar recursos que pueden llegar a ser valiosos después.